```
Analiza wielowymiarowa - projekt 3
04/02/2021
Przygotowanie danych
Po wczytaniu danych doszło do złączenia wszystkich indeksów w jedną ramkę. Zebrane dane są w formacie miesięcznym. Wykorzystano wartości
poszczególnych indeksów z ich zamknięcia. Dane pochodzą z lat 2006-2020. Ich źródłem była strona www.stooq.pl.
W przedstawionym projekcie wykorzystano następujące czynniki:
- WIG - główny indeks giełdy amerykańskiej,
- 1ply_m - rentowność 10-letnich obligacji w Polsce,
- eurpln - wartość eur względem pln - dax_m - indeks DAX - cpiypl - wskaźnik inflacji CPI
 par(mfrow=c(2,2))
 plot(danef$data, danef[,2], type="l", main="wig")
 plot(danef$data, danef[,3], type="l", main="cpi")
 plot(danef$data, danef[,4], type="l", main="eur/pln")
 #plot(danef$data, danef[,5], type="l", main="bezrobocie")
 plot(danef$data, danef[,5], type="1", main="rent.obligacji")
                                                                       срі
                2010
                          2015
                                    2020
                                                               2010
                                                                         2015
                                                                                   2020
                      danef$data
                                                                    danef$data
                      eur/pln
                                                                 rent.obligacji
                                                   2
                                                    3
                2010
                          2015
                                    2020
                                                               2010
                                                                         2015
                                                                                   2020
                     danef$data
                                                                    danef$data
 plot(danef$data, danef[,6] ,type="1", main="dax")
                        dax
                      danef$data
Sprawdzenie stacjonarności
Sprawdzenie stacjonarności surowych danych nastąpi poprzez wykorzystanie testu ADF. Jego hipotezy prezentują się następująco:
                                                  H_0: szereg jest niestacjonarny.
                                                   H_1: szereg jest stacjonarny.
 adf.test(danef[,2] ,alternative = c("stationary"))
 ## Augmented Dickey-Fuller Test
  ## data: danef[, 2]
 ## Dickey-Fuller = -3.2737, Lag order = 5, p-value = 0.0776
 ## alternative hypothesis: stationary
 adf.test(danef[,3] ,alternative = c("stationary"))
 ## Augmented Dickey-Fuller Test
 ## data: danef[, 3]
 ## Dickey-Fuller = -1.7278, Lag order = 5, p-value = 0.69
 ## alternative hypothesis: stationary
 adf.test(danef[,4] ,alternative = c("stationary"))
 ## Augmented Dickey-Fuller Test
  ## data: danef[, 4]
 ## Dickey-Fuller = -4.1557, Lag order = 5, p-value = 0.01
  ## alternative hypothesis: stationary
 adf.test(danef[,5] ,alternative = c("stationary"))
 ## Augmented Dickey-Fuller Test
  ## data: danef[, 5]
 ## Dickey-Fuller = -2.3345, Lag order = 5, p-value = 0.4364
 ## alternative hypothesis: stationary
 adf.test(danef[,6] ,alternative = c("stationary"))
 ## Augmented Dickey-Fuller Test
 ## data: danef[, 6]
 ## Dickey-Fuller = -2.5777, Lag order = 5, p-value = 0.3347
 ## alternative hypothesis: stationary
 #adf.test(danef$bezrobocie ,alternative = c("stationary"))
Stacjonarnosc wystapila jedynie w przypadku wskaźnika eur/pln. Z tego powodu chcąc otrzymać stacjonarne szeregi zdecydowano się na
wykorzystanie logarytmu w celu stworzenia wygładzonych danych.
Poniżej obliczono logarytmy poszczególnych szeregów. W przypadku wartosci wskaznika CPI(ze wzgledu na wystepowanie wartosci '0')
wykorzystano roznice miedzy wartosciami w sasiednich miesiacach.
  #funkcja liczaca stopy logarytmiczne
 data_log <- matrix(nrow = nrow(danef)-1, ncol=ncol(danef)-1)</pre>
  for(i in 2:nrow(danef))
   for(j in 2:6)
     if(j!=3)
       data_log[i-1,j-1]= log(danef[i,j]/danef[i-1,j])
 data_log <- as.data.frame(data_log)</pre>
 colnames(data_log) <- c("wig", "cpi", "eur/pln", "rent.obligacji", "dax")</pre>
 data_log[,2] <- danef[2:181,5] - danef[1:180,5]
 rownames(data_log) <- rownames(danef[2:nrow(danef),])</pre>
Sprawdzenie stacjonarności logarytmów utworzonych zmiennych poprzez wykorzystanie testu ADF (hipotezy testowe takie same jak w
poprzednim przypadku):
 ## Augmented Dickey-Fuller Test
 ## data: data_log[, 1]
 ## Dickey-Fuller = -4.6637, Lag order = 5, p-value = 0.01
 ## alternative hypothesis: stationary
 ## Augmented Dickey-Fuller Test
  ## data: data_log[, 2]
 ## Dickey-Fuller = -5.874, Lag order = 5, p-value = 0.01
 ## alternative hypothesis: stationary
 ## Augmented Dickey-Fuller Test
 ## data: data_log[, 3]
 ## Dickey-Fuller = -6.1153, Lag order = 5, p-value = 0.01
  ## alternative hypothesis: stationary
  ## Augmented Dickey-Fuller Test
 ## data: data_log[, 4]
 ## Dickey-Fuller = -6.0944, Lag order = 5, p-value = 0.01
  ## alternative hypothesis: stationary
 ## Augmented Dickey-Fuller Test
 ## data: data_log[, 5]
 ## Dickey-Fuller = -5.7472, Lag order = 5, p-value = 0.01
 ## alternative hypothesis: stationary
Można zauważyć, iż odnotowano oczekiwany rezultat - po wykorzystaniu funkcji logarytmu i utworzeniu logarytmów wszystkie zmienne są
stacjonarne, gdyż doszło do odrzucenia hipotez zerowych. Oznnacza to, iż po jednym zróżnicowaniu można otrzymać stacjonarny zestaw danych.
Dzięki temu wiadomo, iż na danych z tego projektu można zbudować model VECM.
Model VAR
Kolejnym krokiem jest wybór opóźnienia w modelu VAR. Jest to dosyć często bardzo problematyczne zagadnienie. Na potrzeby tego projektu
wykorzystana zostanie funkcja VARselect. Poniżej wyświetlono poniżej cztery kryteria informacyjne, które będą pomocne w ostatecznym wyborze
opóźnienia w modelu VAR. Są to:

    kryterium informacyjne Akaikego,

    kryterium Hannana-Quinna,

    kryterium Schwarza,

    kryterium Final Prediction Error.

 kable(VARselect(danef[2:6]), format="markdown")
 AIC(n) 2 AIC(n) 1.710478e+01 1.702944e+01 1.706322e+01 1.718352e+01 1.734129e+01 1.755199e+01 1.754190e+01 1.763042e+01 1.775244e+01 1.780528e+01
 HQ(n) 1 HQ(n) 1.732842e+01 1.743945e+01 1.765960e+01 1.796626e+01 1.831040e+01 1.870747e+01 1.888374e+01 1.915863e+01 1.946702e+01 1.970623e+01
 SC(n) 1 SC(n) 1.765595e+01 1.803992e+01 1.853300e+01 1.911261e+01 1.972969e+01 2.039970e+01 2.084891e+01 2.139674e+01 2.197807e+01 2.249022e+01
 FPE(n) 2 FPE(n) 2.682710e+07 2.489875e+07 2.580205e+07 2.920204e+07 3.438635e+07 4.280883e+07 4.287728e+07 4.758451e+07 5.486031e+07 5.933764e+07
Jak można zauważyć, dwa kryteria informacyjne wskazują opóźnienie rzędu 1 jako najlepsze rozwiązanie. Taka sama liczba kryteriów wskazuje
również, iż opóźnienie rzędu 2 jest lepszym wyborem i na potrzeby tego projektu uznano, iż ostatecznie za wartość p w modelu VAR przyjęta
zostanie wartość 2.
Test Johansena
W praktyce wyznaczenie relacji kointegrujących jest dosyć trudnym zagadnieniem. O skointegrowaniu zmiennych mowa, kiedy zmienne
występujące w modelu są niestacjonarne, jednak liniowe kombinacje tych zmiennych są stacjonarne.Natomiast wyznaczenie wektorów
kointegrujących w modelu może dać podstawy do twierdzenia o istnieniu długookresowych związków przyczynowo-skutkowych pomiędzy
zmiennymi modelu. W tym celu zostanie wykorzystany test Johansena, który pozwoli na ustalenie czy pomiędzy określonymi zmiennymi zachodzi
zjawisko kointegracji oraz posłuży on do ustalenia ewentualnego stopnia kointegracji.
Wykorzystując test Johansena weryfikacji poddane zostaną następujące hipotezy:
                                                      H_0: rank(\Pi)=r_0
                                                 H_1: r_0 < rank(\Pi) \leq r_0 + 1
Soren Johansen wprowadził dwa testy: test śladu oraz test największej wartości własnej. Na potrzeby projektu wykorzystane zostaną obie metody
i porównane zostaną rezultaty uzyskane przy ich wykorzystaniu.
 #test Johansena - do sprawdzenia stopnia kointegracji
 jotest1<-ca.jo(danef[2:6],type="eigen",K = 2,ecdet = "none",spec = "longrun") #test największej wartości własnej</pre>
 summary(jotest1)
  ## ######################
  ## # Johansen-Procedure #
  ## #########################
 ## Test type: maximal eigenvalue statistic (lambda max) , with linear trend
  ## Eigenvalues (lambda):
  ## [1] 0.1652109799 0.0998294075 0.0748922815 0.0310177025 0.0001187644
  ## Values of teststatistic and critical values of test:
              test 10pct 5pct 1pct
 ## r <= 4 | 0.02 6.50 8.18 11.65
  ## r <= 3 | 5.64 12.91 14.90 19.19
  ## r <= 2 | 13.93 18.90 21.07 25.75
  ## r <= 1 | 18.83 24.78 27.14 32.14
  ## r = 0 | 32.32 30.84 33.32 38.78
 ## Eigenvectors, normalised to first column:
 ## (These are the cointegration relations)
                            wig.12 cpi.12 eurpln.12 rent.obligacji.12
  ## wig.12
                         1.000000
                                     1.00000
                                                                       1.0000
  ## cpi.l2
                        709.922253 3335.14239 1491.773392
                                                                 -501868.1185
  ## eurpln.12
                      33992.327870 75100.70244 -4305.929668
                                                                  -28630.5008
 ## rent.obligacji.l2 -7341.801426 31359.48568 -5076.611924
                                                                  661117.2049
  ## dax.12
                         -7.795262 13.97609 -4.301312
                                                                     248.4516
                           dax.12
                         1.00000
  ## wig.12
  ## cpi.l2
                      -3116.86275
  ## eurpln.12
                      20381.09887
 ## rent.obligacji.l2 68381.74618
  ## dax.12
                        -10.01176
 ## Weights W:
 ## (This is the loading matrix)
                                         cpi.12 eurpln.12 rent.obligacji.12
  ## wig.d
                      8.298726e-02 4.887229e-04 -1.035465e-01
                                                                   1.403057e-04
                     -1.867730e-07 1.279706e-06 1.545354e-06
  ## cpi.d
                                                                   7.417681e-08
  ## eurpln.d
                      -2.705672e-06 -7.762190e-07 1.991192e-07
                                                                  -2.081795e-09
  ## rent.obligacji.d -1.127969e-06 -1.795818e-06 2.233768e-06
                                                                   2.517850e-08
                      1.918739e-02 -3.637515e-04 2.294217e-03
  ## dax.d
                                                                 1.050364e-05
                            dax.12
                     -7.712686e-06
  ## wig.d
                      -7.116878e-09
  ## cpi.d
  ## eurpln.d
                      -2.187336e-09
  ## rent.obligacji.d 1.308358e-08
                     -1.080034e-05
  ## dax.d
  jotest2<-ca.jo(danef[2:6],type="trace",K = 2,ecdet = "none",spec = "longrun") #test śladu</pre>
  summary(jotest2)
  ## ########################
  ## # Johansen-Procedure #
  ## ##########################
  ## Test type: trace statistic , with linear trend
  ## Eigenvalues (lambda):
  ## [1] 0.1652109799 0.0998294075 0.0748922815 0.0310177025 0.0001187644
 ## Values of teststatistic and critical values of test:
              test 10pct 5pct 1pct
  ## r <= 4 | 0.02 6.50 8.18 11.65
  ## r <= 3 | 5.66 15.66 17.95 23.52
 ## r <= 2 | 19.60 28.71 31.52 37.22
 ## r <= 1 | 38.42 45.23 48.28 55.43
  ## r = 0 | 70.74 66.49 70.60 78.87
 ## Eigenvectors, normalised to first column:
  ## (These are the cointegration relations)
                            wig.12 cpi.12 eurpln.12 rent.obligacji.12
  ## wig.12
                         1.000000 1.00000
                                                  1.000000
                                                                       1.0000
  ## cpi.l2
                        709.922253 3335.14239 1491.773392
                                                                 -501868.1185
  ## eurpln.12
                      33992.327870 75100.70244 -4305.929668
                                                                  -28630.5008
  ## rent.obligacji.l2 -7341.801426 31359.48568 -5076.611924
                                                                  661117.2049
  ## dax.12
                         -7.795262 13.97609 -4.301312
                                                                     248.4516
                          dax.12
                         1.00000
  ## wig.12
  ## cpi.12
                       -3116.86275
  ## eurpln.12
                      20381.09887
  ## rent.obligacji.l2 68381.74618
  ## dax.12
                        -10.01176
  ## Weights W:
 ## (This is the loading matrix)
                                       cpi.12 eurpln.12 rent.obligacji.12
                      8.298726e-02 4.887229e-04 -1.035465e-01
                                                                   1.403057e-04
  ## wig.d
                     -1.867730e-07 1.279706e-06 1.545354e-06 7.417681e-08
  ## cpi.d
  ## eurpln.d
                     -2.705672e-06 -7.762190e-07 1.991192e-07 -2.081795e-09
  ## rent.obligacji.d -1.127969e-06 -1.795818e-06 2.233768e-06 2.517850e-08
                      1.918739e-02 -3.637515e-04 2.294217e-03 1.050364e-05
  ## dax.d
                            dax.12
                     -7.712686e-06
  ## wig.d
                     -7.116878e-09
  ## cpi.d
  ## eurpln.d
                     -2.187336e-09
 ## rent.obligacji.d 1.308358e-08
                     -1.080034e-05
  ## dax.d
Jak można zauważyć, po przyjęciu poziomu istotności na poziomie 0,05, w pierwszym przypadku dochodzi do odrzucenia hipotezy zerowej
wskazującej na brak kointegracji w przypadku testu śladu. Test wartosci wlasnej nie dal podstaw do odrzucenia H0 na poziomie 0,05 (ale mialo to
miejsce juz na poziomie 10%) Gdy badana jest z kolei kointegracja dla r \le 1 nie ma już podstaw do odrzucenia hipotezy zerowej. Taka sytuacja
również zachodzi w obu przypadkach. Ostatecznie, rozwiązanie wskazuje jednoznacznie na wystepowanie relacji kointegrujących. Mówiąc
precyzyjniej, zachodzi jedna relacja kointegrująca. Informacja ta zostanie wykorzystana podczas tworzenia modelu VECM.
Model VECM
Estymując model VEC należy przyjąć określoną wartość parametrów. W tym projekcie będzie to VECM(1), gdyż tworząc model VECM należy
uwzględnić opóźnienie o 1 mniejsze, niż w przypadku modelu VAR. Podczas konstruowania modelu VEC konieczne będzie odwołanie się do
wcześniej wykazanej kointegracji zachodzącej pomiędzy zmiennymi. Dzięki temu można określić, iż wartość parametru r wyniesie dokładnie 1.
  model_VECM<-VECM(danef[2:6], lag = 1, r=1, estim = "ML")</pre>
  #model_VAR <- VAR(danef[2:6],p=2)</pre>
  #summary(model_VAR)
 summary(model_VECM)
  ## ############
  ## ###Model VECM
  ## ############
  ## Full sample size: 181 End sample size: 179
  ## Number of variables: 5 Number of estimated slope parameters 35
  ## AIC 3047.271 BIC 3171.579 SSR 1173269774
 ## Cointegrating vector (estimated by ML):
  ## wig cpi eurpln rent.obligacji
  ## r1 1 709.9223 33992.33 -7341.801 -7.795262
                             ECT
                                                  Intercept
                            0.0830(0.0246)***
                                                  -7311.4092(2220.4350)**
  ## Equation wig
                            -1.9e-07(3.2e-06)
  ## Equation cpi
                                                  0.0271(0.2871)
                            -2.7e-06(7.9e-07)*** 0.2428(0.0714)***
  ## Equation eurpln
 ## Equation rent.obligacji -1.1e-06(2.2e-06)
                                                  0.0743(0.2011)
                            0.0192(0.0035)***
                                                  -1685.4570(319.3638)***
  ## Equation dax
                             wig -1
                                                  cpi -1
                            -0.0234(0.0938)
                                                  -1254.4716(576.2084)*
  ## Equation wig
                             9.5e-06(1.2e-05)
                                                 0.2322(0.0745)**
  ## Equation cpi
  ## Equation eurpln
                             3.1e-06(3.0e-06)
                                                 0.0123(0.0185)
 ## Equation rent.obligacji 1.1e-05(8.5e-06)
                                                 0.1147(0.0522)*
                             -0.0122(0.0135)
                                                  -27.1528(82.8757)
  ## Equation dax
                                                     rent.obligacji -1
                             eurpln -1
                             -4403.5481(2781.4163) 912.6123(871.5250)
  ## Equation wig
  ## Equation cpi
                            0.4143(0.3596)
                                                      0.3695(0.1127)**
                            0.3676(0.0894)***
                                                      -0.1064(0.0280)***
  ## Equation eurpln
 ## Equation rent.obligacji 0.4307(0.2519).
                                                      -0.0525(0.0789)
                                                     -16.6723(125.3509)
  ## Equation dax
                             -677.3345(400.0494).
                             dax -1
                            0.0660(0.5925)
  ## Equation wig
                            0.0001(7.7e-05).
  ## Equation cpi
                             2.0e-06(1.9e-05)
  ## Equation eurpln
 ## Equation rent.obligacji 8.0e-05(5.4e-05)
                            0.0020(0.0852)
  ## Equation dax
Zaczynając od interpretacji równania dotyczącego relacji kointegrujących, w przypadku wyestymowanego modelu zasugerowany został pozytywny
wpływ wskaźnika inflacji CPI na wartość indeksu WIG, podobna sytuacja ma miejsce, jeśli chodzi o parę Eur/pln, przeciwny wpływ na wartość
indeksu wydają się mieć wartości dotyczące rentowności obligacji oraz indeksu DAX.
Analizując wartości ECT można uzyskac informację o długoterminowym wpływie poszczególnych czynników na WIG. W przypadku badanego
modelu istotny statystycznie długoterminowy wpływ okazał się mieć miejsce dla pary walutowej eur/pln oraz indeksu dax.
Jeśli chodzi o krótkoterminowy wpływ, na wartość indeksu wig nieznacznie wpływa inflacja CPI. W przypadku pary walutowej eur/pln
krótkoterminowo wpływa na ona sama (z opóźnieniem I = 1), jak i również widoczny jest statystycznie istotny wpływ rentowności obligacji na
```

##

##

##

##

##

wartość złotówki wzgledęm euro.